

VILNIAUS UNIVERSITETSS  
MATEMATIKOS IR INFORMATIKOS FAKULTETAS  
INFORMATIKOS INSTITUTAS  
PROGRAMŲ SISTEMŲ BAKALAURO STUDIJŲ PROGRAMA

# **Perceptrono mokymas sprendžiant klasifikavimo uždavinį**

## **Artificial Neuron Model**

Laboratorinio darbo ataskaita

Atliko: Armintas Pakenis

Darbo vadovas: prof. dr. Olga Kurasova

Vilnius – 2023

## **TURINYS**

1. UŽDUOTIES TIKSLAS .....	2
1.1. Duomenys.....	2
2. PERCEPTRONO MOKYMAS .....	3
2.1. Iteracijos ir epochos.....	3
2.2. Pradiniai svoriai ir poslinkis .....	3
3. REZULTATAI .....	4
4. IŠVADOS .....	8

# 1. Užduoties tikslas

Užduoties tikslas — suprasti dirbtinio neurono modelį, jo veikimo principus ir tinkamai įgyvendinti jo mokymąsi dviejų klasių klasifikavimo uždaviniui. Programoje naudotos bibliotekos: numpy ir matplotlib. Programos kodas rašytas Jupyter užrašų knygutės aplinkoje jį rasti galima GitHub repozitorijoje: <https://github.com/ArmintasP/Computational-intelligence/tree/main/Lab2>.

## 1.1. Duomenys

Naudoti irisų duomenų ir krūties vėžio duomenų rinkiniai: <https://archive.ics.uci.edu/ml/datasets/iris> ir [https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+\(Diagnostic\)](https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+(Diagnostic)).

Failai prieš mokymą apdoroti, pašalintos įeitys, turinčios trūkstančių požymių. Apdorotame irisų duomenų rinkinyje buvo 100, iš kurių po 50 įrašų kiekvienos klasės. Požymių skaičius — 4. Apdorotame krūties vėžio duomenų rinkinyje buvo 683, iš kurių po 239 priklausė vienai klasei, likusieji — kitai. Požymių skaičius šiam rinkiniui — 10.

Įeičių tvarka prieš pradedant mokymą buvo sumaišyta, nes norėta išvengti tik vienos klasės įeičių mokymo rinkinyje. 80 procentų įeičių (kartu su trokštamomis reikšmėmis) buvo naudojami mokymo rinkinyje. Likusi dalis — validavimo rinkinyje.

## **2. Perceptrono mokymas**

### **2.1. Iteracijos ir epochos**

Epocha — mokymo proceso dalis, kuriuos metu apdorojamas mokymo ir validavimo įeičių rinkinys tik vieną kartą. Šiame darbe duomenų rinkiniai nebuvo skaidomi į mažesnius rinkinius, iteracijų vienoje epochoje buvo tiek, kiek duomenų rinkinyje įrašų (100 ir 683).

### **2.2. Pradiniai svoriai ir poslinkis**

Pradinės svorių reikšmės ir poslinkis buvo parenkami atsitiktinai, pagal Gauso skirstinį, kitaip tariant,  $\mathbf{w} \sim \mathcal{N}(0, 1)$ . Mokymu metu svoriai buvo ieškomi pasitelkiant ADALINE mokymo taisyklę.

### 3. Rezultatai

Variantai, kada gaunami tiksliausi klasifikavimo rezultatai ir mažiausia paklaida, su pateiktais svoriais, nuostolių funkcijų reikšmėmis, epochų skaičiumi, klasifikavimo tikslumo įverčiais, bei kokias klases identifiko perceptronas iš validavimo duomenų aibės yra pateikti tekstiniuose failuose kiekvienam duomenų kiekiui su skirtinga aktyvacijos funkcija repozitorijoje: <https://github.com/ArminasP/Computational-intelligence/tree/main/Lab2/Results>.

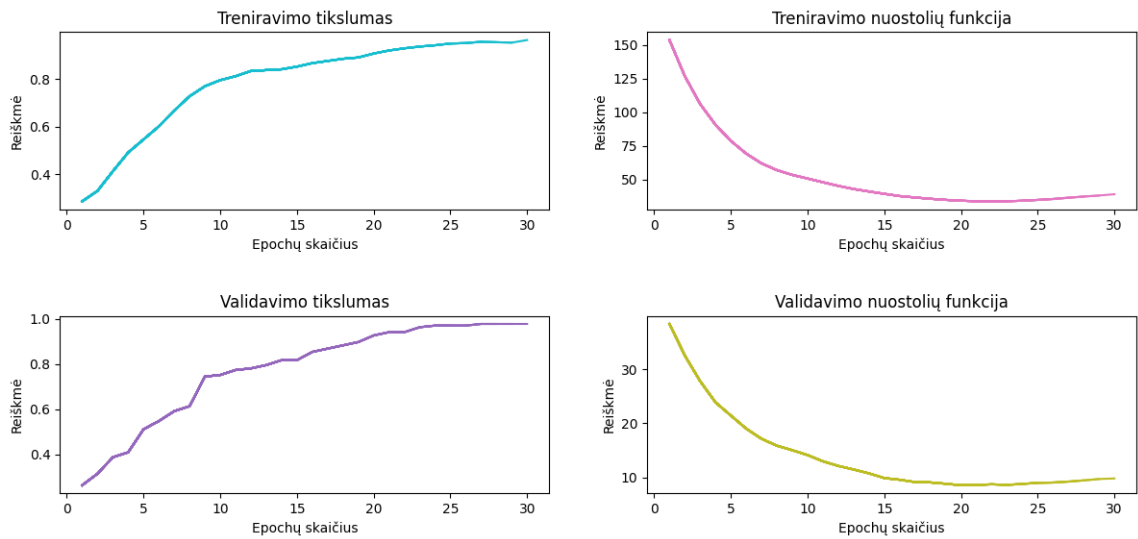
Tiek treniravimo, tiek validavimo duomenims klasifikavimo tikslumas didėja, jei epochų skaičius didėja. Be to, matoma, jog dažnai validavimo rinkinio klasifikavimo tikslumas yra mažesnis nei treniravimo. Tai matyti iš visų žemiau esančių paveikslėlių su grafikais (žr. 1, 2, 3, 4 paveikslėlius). Tačiau galima pastebėti, kad esant dideliame epochų skaičiui, modelis persimoko. Pavyzdžiui, 3 ir 4 paveikslėliuose matyti, kad nuo 40 epochos klasifikavimo tikslumas tampa nebe stabilus, įgyja net mažesnes reikšmes už pasiektas anksčiau.

Tiek treniravimo, tiek validavimo duomenims nuostolių funkcijos reikšmė mažėja, jei epochų skaičius didėja. Neintuityviai gali atrodyti, jog validavimo duomenims nuostolių funkcija turi daug mažesnes reikšmes nei treniravimo duomenys. Taip atsitinka todėl, kad validavimo duomenų turime mažiau ir naudojame vidutinę paklaidos funkciją  $\frac{1}{2} \sum_{i=1}^n (x_i - y_i)^2$ . Egzistuoja ta pati problema kaip su klasifikavimo tikslumu — didėjant epochų skaičiui, didėja tikimybė modeliui persimokyti. Tai labiausiai galime pamatyti 3 ir 4 paveikslėliuose, kur nuo 60 epochos modelis persimoko.

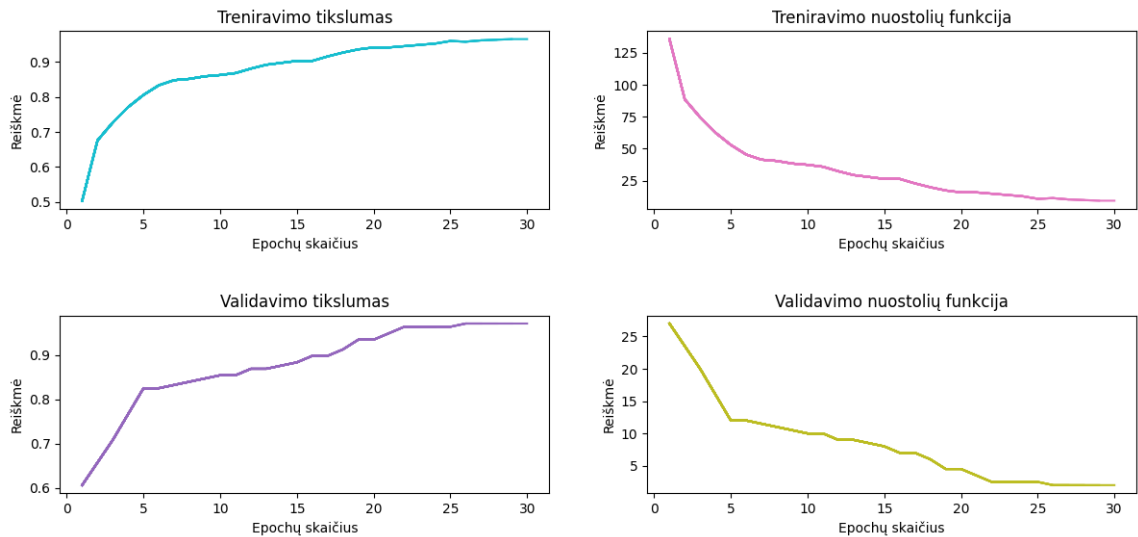
Krūties vėžio duomenų aibė daug jautresnė modelio persimokymui lyginant su irisų duomenų aibę. Taip yra todėl, kad dėl krūties vėžio duomenys turi daugiau požymių ir turime bent 6 kartus daugiau įrašų.

Toliau aptariant minėtus grafikus, ženklau pranašumo tarp sigmoidinės ir slenkstinės aktyvacijos funkcijų nematyti. Tiesa, panašu, kad su mažesniu duomenų rinkiniu sigmoidine funkcija yra stabilesnė nei slenkstinė (žr. 3 ir 4 paveikslėlius).

Aiškios tendencijos tarp mokymosi greičio ir nuostolių funkcijos reikšmių ar klasifikavimo tikslumo su duotais rinkiniais nėra (žr. 1, 2, 3, 4 lenteles). Tiesa, irisų duomenų rinkinys turėjo didesnę skirstumą tarp treniravimo ir validavimo duomenų rinkinių, kai buvo skirtingi mokymosi greičiai.



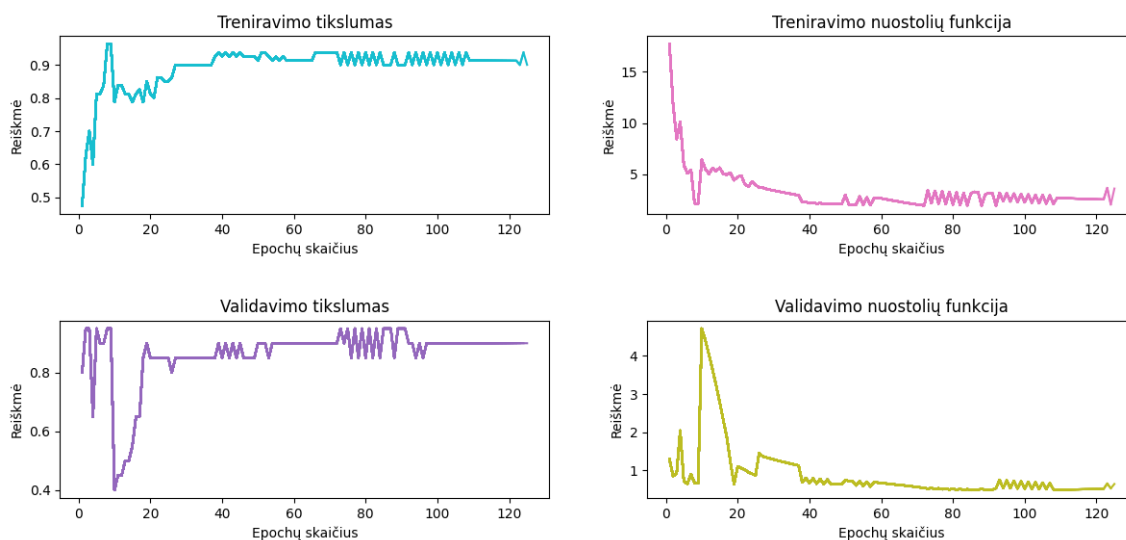
1 pav. Perceptrono mokymas naudojant krūties vėžio duomenų rinkinį ir sigmoidinę aktyvacijos funkciją. Epochų skaičius: 30, mokymosi greitis: 0,001



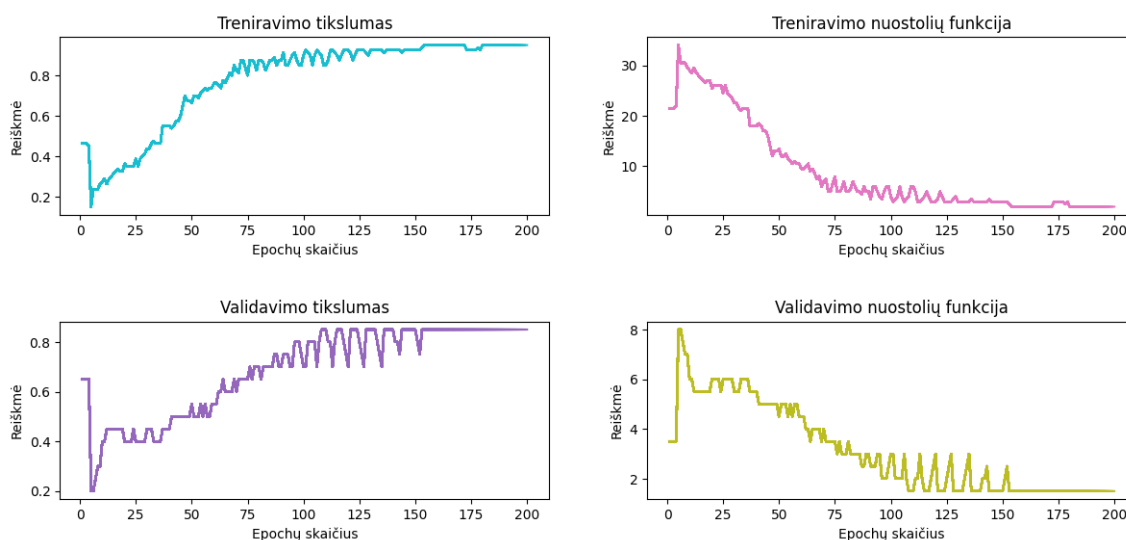
2 pav. Perceptrono mokymas naudojant krūties vėžio duomenų rinkinį ir slenkstinę aktyvacijos funkciją. Epochų skaičius: 30, mokymosi greitis: 0,001

1 lentelė. Krūties vėžio duomenų rinkinio rezultatai, epochų skaičius = 100

Mokymosi greitis	Tikslumas		Nuostolių f. reikšmė	
	Treniravimo	Validavimo	Treniravimo	Validavimo
0,001	0,95	0,97	61,35	15,44
0,01	0,96	0,96	19,6	4,88
1	0,95	0,97	10,98	1,99



3 pav. Perceptrono mokymas naudojant irisų duomenų rinkinį ir sigmoidinę aktyvacijos funkciją. Epochų skaičius: 125, mokymosi greitis: 0,1



4 pav. Perceptrono mokymas naudojant irisų duomenų rinkinį ir slenkstinę aktyvacijos funkciją. Epochų skaičius: 200, mokymosi greitis: 0,001

2 lentelė. Krūties vėžio duomenų rinkinio rezultatai, epochų skaičius = 10

Mokymosi greitis	Tikslumas		Nuostolių f. reikšmė	
	Treniravimo	Validavimo	Treniravimo	Validavimo
0,001	0,82	0,79	40,80	10,79
0,01	0,93	0,92	35,60	9,79
1	0,94	0,95	16,39	3,53

3 lentelė. Irisų duomenų rinkinio rezultatai, epochų skaičius = 100

Mokymosi greitis	Tikslumas		Nuostolių f. reikšmė	
	Treniravimo	Validavimo	Treniravimo	Validavimo
0,001	0,85	0,85	6,55	1,63
0,01	0,91	0,85	6,31	1,63
1	0,94	0,9	2,25	1,00

4 lentelė. Irisų duomenų rinkinio rezultatai, epochų skaičius = 10

Mokymosi greitis	Tikslumas		Nuostolių f. reikšmė	
	Treniravimo	Validavimo	Treniravimo	Validavimo
0,001	0,68	0,8	8,12	1,99
0,01	0,56	0,7	9,59	2,25
1	0,81	0,5	7,19	4,99



## 4. Išvados

Didinant epochų skaičių, didėja klasifikavimo tikslumas. Esant per dideliui epochų skaičiui modelis tampa permokytu. Ženklaus skirtumo tarp slenkstinės ir sigmoidinės funkcijų nepastebėta. Tendencijų kintant mokymosi greičiui nerasta, tačiau palyginimai atlikti nefiksuojant svorių inicializavimo. Siekiant labiau ištirti mokymosi greičio įtaką neurono mokymuisi, reikia pakartoti eksperimentą ne tik su fiksuotu epochų skaičiumi, bet ir fiksuotais pradiniais svoriais.